

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ ФЕДЕРАЛЬНОЕ
ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский ядерный университет «МИФИ»
Обнинский институт атомной энергетики –
филиал федерального государственного автономного образовательного учреждения высшего
образования «Национальный исследовательский ядерный университет «МИФИ»
(ИАТЭ НИЯУ МИФИ)

Отделение интеллектуальных кибернетических систем

ЛАБОРАТОРНАЯ РАБОТА №3
«Анализ набора данных»
по дисциплине
«Большие данные»

Выполнил студент 1 курса
группы ИВТ-М20
Лискунов Р. Г.

Проверил:
кандидат технических наук
Грицюк С. В.

Цель работы

Проанализировать набор данных (популярные детские имена) с помощью Spark SQL (работа на одной машине с несколькими потоками без полноценной среды Hadoop) и визуализировать при помощи библиотеки Vegas.

Краткая теория

Spark SQL – это модуль Apache Spark, интегрирующий реляционную обработку данных и процедурный API Spark. Spark SQL является частью ядра Spark с версии 1.0. Он может работать совместно с Hive (HiveQL/SQL) или замещать его.

Благодаря Spark SQL, функционал фреймворка получает два ключевых дополнения. Во-первых, модуль обеспечивает тесную интеграцию между реляционной и процедурной обработкой данных посредством интеграции декларативного DataFrame API и процедурного API Spark. Во-вторых, он включает в себя расширяемый оптимизатор, созданный на языке Scala, обладающем широкими возможностями сопоставления с образцом (pattern matching), что позволяет легко формировать правила, управлять генерацией кода и создавать расширения.

Spark SQL и DataFrame

DataFrame – это распределенная коллекция данных, организованных посредством именованных столбцов. Данная абстракция предназначена для выборки, фильтрации, агрегации и визуализации структурированных данных.

DataFrame поддерживает глубокую реляционную/процедурную интеграцию в рамках программ Spark и позволяет манипулировать данными как с помощью процедурного API Spark, так и посредством нового реляционного API, обеспечивающего более эффективную оптимизацию. DataFrame может быть создан непосредственно из RDD, что обеспечивает возможность реляционной обработки уже имеющихся данных.

DataFrame предоставляет более удобные и эффективные средства обработки данных, чем процедурный API Spark. В частности, можно вычислить несколько агрегаций за один проход с мощностью SQL-инструкции, что достаточно сложно реализовать посредством традиционного процедурного API.

В отличие от RDD, DataFrame отслеживает свою схему и поддерживает различные реляционные операции, что обеспечивает более оптимизированное выполнение. DataFrame формирует схему посредством отражения (reflection).

DataFrame является «ленивой» структурой данных, то есть содержит логический план для вычисления набора данных, при этом вычисления не выполняются до тех пор, пока пользователь не запросит специальную «операцию вывода», например, сохранение. Такой подход обеспечивает эффективную оптимизацию всех операций.

Концепция DataFrame расширяет модель RDD. В результате, благодаря упрощенным методам фильтрации и агрегации, Spark-разработчики получают возможность быстрее и эффективнее работать с большими наборами структурированных данных.

Ход работы

В процессе работы мы рассмотрим набор данных, состоящий из популярных детских имен. Прежде всего мы ознакомимся с структурой данной информации. Набор данных представляет из себя файл с расширением CSV (Comma-Separated Values — значения, разделённые запятыми). Его заголовок содержит следующие поля:

- | | |
|------------------|-----------------------|
| 1. Year of Birth | 4. Child's First Name |
| 2. Gender | 5. Count |
| 3. Ethnicity | 6. Rank |

Приведём пример на рисунке 1 первых 20 записей в этом наборе данных.

```

+-----+-----+-----+-----+-----+-----+
|Year of Birth|Gender|Ethnicity|Child's First Name|Count|Rank|
+-----+-----+-----+-----+-----+-----+
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Olivia|172|1|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Chloe|112|2|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Sophia|104|3|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Emma|99|4|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Emily|99|4|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Mia|79|5|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Charlotte|59|6|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Sarah|57|7|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Isabella|56|8|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Hannah|56|8|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Grace|54|9|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Angela|54|9|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Ava|53|10|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Joanna|49|11|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Amelia|44|12|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Evelyn|42|13|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Ella|42|13|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Arya|42|13|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Ariana|40|14|
|2016|FEMALE|ASIAN AND PACIFIC ISLANDER|Maya|39|15|
+-----+-----+-----+-----+-----+-----+
only showing top 20 rows

```

Рисунок 1. Визуализация набора данных

На последнем столбце остановимся поподробнее. Исследуем его корреляции с количественным показателем числа имен, которые встречаются в данном наборе. Взаимосвязь представлена на рисунке 2.




Рисунок 2. Взаимосвязь ранга и числа имён

Для того, чтобы начать дополнительный анализ данной взаимосвязи, совершим общий подсчёт числа этносов в наборе данных (рисунок 3).

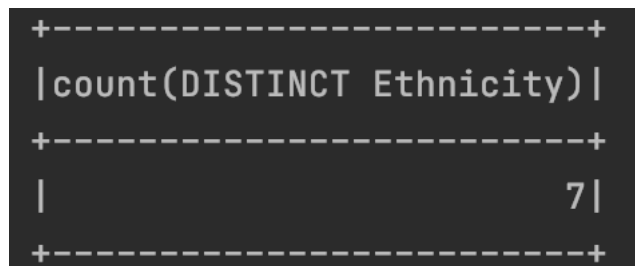


Рисунок 3. Число уникальных этносов

Полученные данные позволяют подробнее рассмотреть связь между значением этнического происхождения и ранга (рисунок 4), а затем сравнить её со связью с числом имён в наборе данных (рисунок 5).

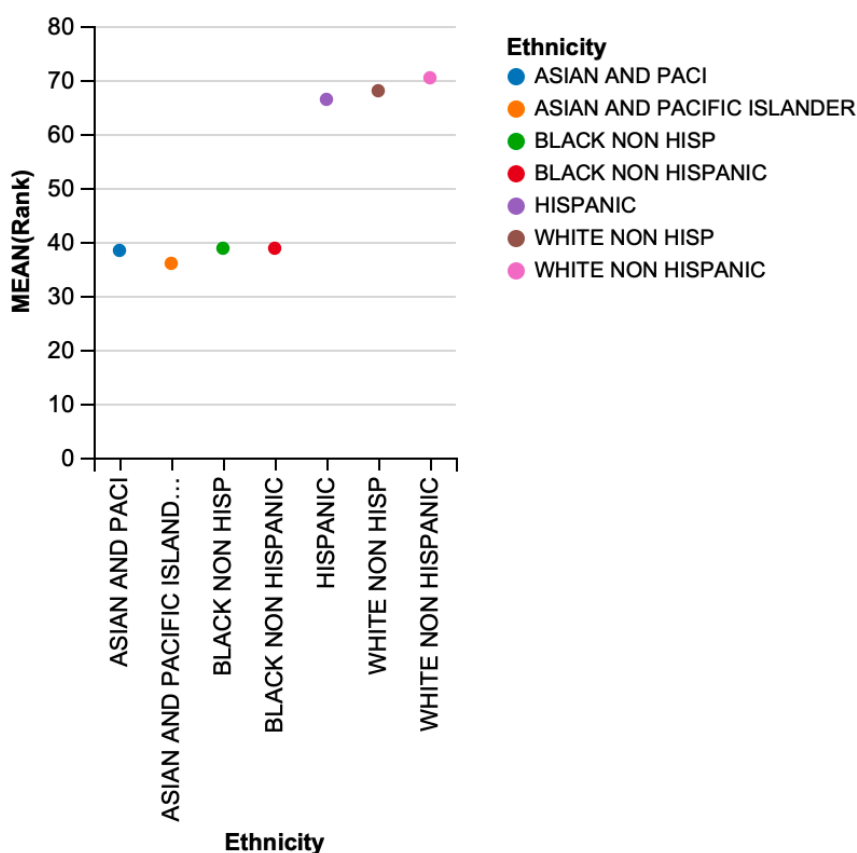


Рисунок 4. Взаимосвязь этноса и ранга

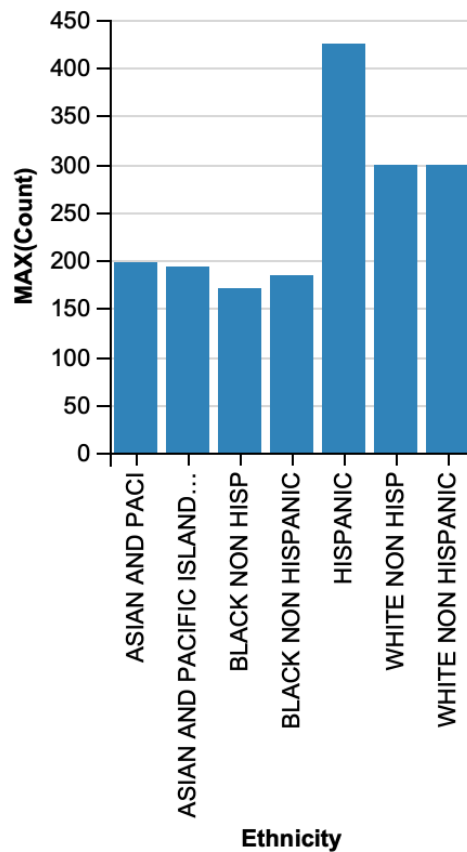


Рисунок 5. Взаимосвязь этноса и числа имён

В ходе анализа мы рассмотрели некоторые из возможных корреляций числа этнических групп в данном наборе данных по отношению к прочим. Для завершения работы численно представим топ 20 самых популярных имён на рисунке 6.

```

+-----+-----+
|Child's First Name|count|
+-----+-----+
| Avery| 38|
| Riley| 33|
| Ariel| 30|
| Dylan| 28|
| Logan| 27|
| Jordan| 27|
| Aaron| 24|
| Caleb| 24|
| Kevin| 24|
| Aria| 24|
| Xavier| 24|
| Nathaniel| 24|
| James| 23|
| Marcus| 23|
| Ariana| 23|
| Kyle| 23|
| Tristan| 23|
| Christopher| 23|
| Grace| 23|
| Naomi| 23|
+-----+-----+
only showing top 20 rows

```

Рисунок 6. Топ 20 популярных имён

```

package LabThree

import org.apache.log4j.Level.WARN
import org.apache.log4j.LogManager
import org.apache.spark.sql.{DataFrame, SparkSession}
import org.apache.spark.sql.functions.countDistinct
import org.apache.spark.sql.functions._
import vegas._
import vegas.sparkExt._

object LabThree {
  val PATH: String = "src/main/data"
  val NODES: Int = 3

  def main(args: Array[String]): Unit = {
    val spark: SparkSession = SparkSession.builder()
      .appName("Lab3")
      .master(s"local[$NODES]")
      .getOrCreate
    LogManager.getRootLogger.setLevel(WARN)

    val dataframe: DataFrame = spark.read
      .format("csv")
      .option("header", "true")
      .option("delimiter", ",")
      .load(s"$PATH/var.csv")

    dataframe.show(false)

    // Correlation between Ethnicity and Count
    Vegas("Children_Info")
      .withDataFrame(dataframe)
      .encodeX(field = "Ethnicity", dataType = Nominal)
      .encodeY(field = "Count", dataType = Quantitative, aggregate = AggOps.Max)
      .mark(Bar)
      .show

    // Correlation between Ethnicity and Rank
    Vegas("Children_Info")
      .withDataFrame(dataframe)
      .encodeX(field = "Ethnicity", dataType = Nominal)
      .encodeY(field = "Rank", dataType = Quantitative, aggregate = AggOps.Mean)
      .encodeColor(field = "Ethnicity", dataType = Nominal)
      .mark(Circle)
      .show

    // Correlation between Count and Rank
    Vegas("Children_Info")
      .withDataFrame(dataframe)
      .encodeX(field = "Count", dataType = Quantitative, sortOrder = SortOrder.Asc)

```

```

.encodeY(field = "Rank", dataType = Quantitative)
.mark(Line)
.show

// Number of unique ethnic groups
dataframe.agg(countDistinct("Ethnicity")).show()
// Top 20 most popular names
dataframe.groupBy("Child's First Name").count().sort(col("count").desc).show()
}
}

```

Вывод

В ходе данной лабораторной работы я изучил особенности и возможности способов работы со Spark SQL и Vegas. Для этого я использовал набор данных популярных детских имен. Подробно остановился на взаимосвязи между этническим происхождением и некоторыми другими параметрами. Исследование показало, что самым популярным именем было Avery из этноса WHITE NON HISPANIC.